# Ambiente e estado markoviano

**Problema.** Dados $n$ livros $\{b_1, \ldots, b_n\}$, encontrar a permutação $\sigma$ das posições da estante que maximiza o lucro esperado das visitas.

**Ambiente.** A biblioteca (estantes com posições $1, \ldots, n$) e seus clientes. Interagimos com um simulador de visitas calibrado com dados históricos (ou com períodos de teste na biblioteca real).

**Construção sequencial.** Em cada passo $t$ o agente preenche a posição $t$; o episódio termina em $t = n$ (horizonte finito $H = n$).

## Estado $s_t$ (o que o agente observa)

$$s_t = \big( t,\ \mathrm{m}_t,\ (b_{\sigma(1)}, \ldots, b_{\sigma(t-1)}),\ X,\ \big)$$

- $t$: posição a preencher (restam $n - t + 1$ decisões);
- $\mathrm{m}_t \in \{0,1\}^n$: livros já alocados;
- ordem parcial já montada;
- $X = [\mathrm{x}_1, \ldots, \mathrm{x}_n]$: características de cada livro,
  $\mathrm{x}_i$ = [tema, avaliação, título (*embedding*), popularidade, margem, preço].

# Por que $s_t$ é markoviano — e ações do agente

## Hipótese de Markov

$P(s_{t+1} \mid s_t, a_t) = P(s_{t+1} \mid h_t, a_t)$: $s_t$ resume a história $h_t$. Se omitíssemos a ordem parcial ou $\mathrm{m}_t$, o futuro dependeria do que foi escolhido antes e a hipótese seria violada.

**Transição.** Determinística: ao escolher o livro $a_t$, $P(s_{t+1} \mid s_t, a_t) = 1$ para o estado em que $t \leftarrow t+1$, $\mathrm{m}_{t+1} = \mathrm{m}_t + \mathrm{e}_{a_t}$ e $a_t$ é anexado à ordem parcial.

## Ações $\mathcal{A}(s_t)$

$$a_t \in \mathcal{A}(s_t) = \{\, i \in \{1, \ldots, n\} : m_{t,i} = 0 \,\}$$

- $a_t = i$: *colocar o livro $b_i$ na posição $t$*;
- ações discretas, com $|\mathcal{A}(s_t)| = n - t + 1$; livros já usados são mascarados;
- toda sequência de $n$ ações válidas é uma permutação válida.

**Estados e políticas.** $|S|$ é da ordem de $n!$ ou mais: nada de tabela. Usamos $\hat{Q}(s, a; \mathrm{w})$ com $X$ como entrada, e política $\epsilon$-gulosa em relação a $\hat{Q}$ para explorar ordenações diferentes.

# Recompensas

**Modelo de recompensa.** $R(s,a) = \mathbb{E}[\, r_t \mid s_t = s,\ a_t = a\,]$. Seja $v(t)$ a probabilidade de a posição $t$ ser vista, $p_i$ a de o livro $b_i$ ser emprestado/comprado dado que foi visto e $\mu_i$ sua margem de lucro.

## Esparsa (fiel ao objetivo)

$$r_t = \begin{cases} 0, & t < n \\ \text{lucro das visitas}, & t = n \end{cases}$$

Retorno $G_1 = r_n$ (com $\gamma = 1$, pois $H < \infty$).

*Desvantagem:* atribuição de crédito difícil.

## Densa (*shaping*)

$$r_t = R(s_t, a_t) = v(t)\, p_{a_t}\, \mu_{a_t}$$

$$G_1 = \sum_{t=1}^{n} r_t$$

*Desvantagem:* depende de um modelo de cliente que pode estar errado.

## A recompensa define o problema

Só receita imediata leva o agente a destacar best-sellers e esconder o resto. Podem-se somar termos de diversidade ou retenção: $r_t \leftarrow r_t + \lambda\, d(s_t, a_t)$.

**Resumo do MDP.** $(S, A, P, R, \gamma)$ com $P$ determinística, $R$ como acima, $\gamma = 1$ e $H = n$. Aprende-se com DQN (repetição de experiência + alvos fixos), alvo $r + \gamma \max_{a'} \hat{Q}(s', a'; \mathrm{w}^-)$.